J1 – Statistiques

Satistiques descriptives

Entrée [1]:

```
import numpy as np
import scipy.stats as st
import pandas as pd

import matplotlib.pyplot as plt
import seaborn as sns
```

Exercice 1 - Quel pourcentile ? (*)

Décrire cette série de nombres avec un maximum de statistiques descriptives.

Hint: Utilisez numpy et scipy

Entrée [2]:

```
test_array = np.array([ 29.06114022,
                                    26.17437913, 36.4492889, 54.90292031,
       49.44535829, 70.72485829, 67.46168782, 77.42488633,
        5.19166198, 46.1153849, 102.91120315, 37.63296073,
       38.20406491, 71.23979213, 50.67913182, 71.61930794,
       36.13388738, 27.3738083, 80.05990108, 64.42082913,
       85.96083068, 38.48042099, 39.96362245, 62.00757552,
       83.12837179, 50.02396422, 73.35132353, 55.20438011,
       45.0256195 ,
                    18.21004262, 46.61125507, 29.79881717,
       19.16614263, 36.87047247, 34.71334354, 85.11379842,
       66.79951584, 61.00108181, 46.82147047,
                                                4.4950038
                    17.01467171, 40.00601743, 35.13955427,
       59.64403006,
                    54.1456781 , 34.30530359, 103.841159
       38.31776797,
       83.36621903, 43.18991314, 46.98826925, 66.62157158,
       41.79001612,
                    40.60759538,
                                  65.20520983, 21.43783658,
       69.52452364,
                    86.3687045 ,
                                  71.41994957, 47.33225797,
                    55.05271646, 41.89208457, 55.22620396,
       21.115204 ,
       51.83378269, 46.00827601, 44.26225881, 83.07739312,
       48.96878562,
                    64.82302883,
                                  25.87666904, 48.55161088,
       48.19525418.
                    47.60694118, 42.81430297, 15.83639471,
       73.88628351, 59.81470386, 36.10382006, 54.88516162,
       63.63872644, 26.40355033, 81.54731183, 26.72902021,
                    29.31653704, 59.08846558, 47.91728695,
       73.58336019,
       20.65932672, 67.37507865, 29.69230719, 35.60901864,
       75.98322683, 74.13652542, 42.1707353, 36.14038798,
       63.02800873, 39.74962657, 23.85164459, 93.0516192 ])
```

Entrée [3]:

```
mean = np.mean(test_array)
median = np.median(test_array)
std = np.std(test_array)
variance = std**2
etendue = np.max(test_array) - np.min(test_array)
q1, q3 = np.quantile(test_array, [0.25, 0.75])
```

Entrée [8]:

```
edian}, \nEcart-type : {std:.3}, \nVariance : {variance:.3}, \nEtendue : {etendue}, \n1er

Moyenne : 50.68,
Médiane : 47.762114065,
Ecart-type : 21.1,
Variance : 4.45e+02,
Etendue : 99.3461552,
```

1er quartile : 36.13876283,
3e quartile : 66.666057645

Entrée [9]:

```
mode = st.mode(test_array)
mode
```

Out[9]:

ModeResult(mode=array([4.4950038]), count=array([1]))

La série de données est continue, toutes les valeurs sont différentes donc le calcul du mode n'a pas d'intérêt (ici c'est simplement la valeur minimale qui est renvoyée).

Entrée [10]:

```
pd.DataFrame(test_array).describe()
```

Out[10]:

```
0
count 100.000000
mean
        50.677424
  std
        21.192488
         4.495004
 min
 25%
        36.138763
 50%
        47.762114
 75%
        66.666058
       103.841159
 max
```

Exercice 2 - Le football est-il relié à l'économie ? (*)

Trouver le coefficient de correlation entre les valeurs du CAC40 et les prix des actions du Groupe OL

Hint: Il existe une fonction de correlation sur numpy

Entrée [11]:

Entrée [12]:

```
np.corrcoef(cac_values, olg_values)
```

Out[12]:

```
array([[1. , 0.87975468], [0.87975468, 1. ]])
```

Entrée [13]:

```
df = pd.DataFrame({"cac": cac_values, "olg": olg_values})
```

Entrée [14]:

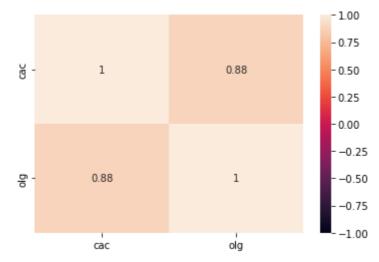
```
df.head()
```

Out[14]:

	cac	olg
0	5197.79	2.34
1	5011.98	2.41
2	5022.38	2.41
3	4858.97	2.32
4	4762.78	2.27

Entrée [15]:

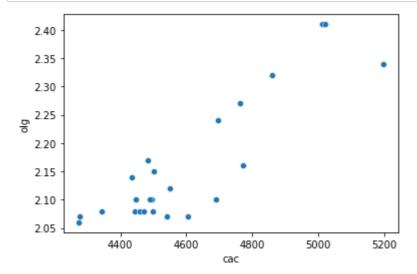
```
sns.heatmap(df.corr(), vmin=-1, annot=True)
plt.show()
```



La corrélation est très proche de 1, regardons ce que cela donne graphiquement ...

Entrée [12]:

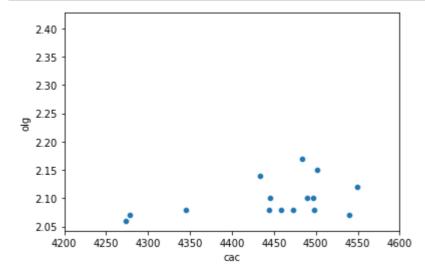
```
sns.scatterplot(data=df, x="cac", y="olg")
plt.show()
```



Si on se restreint aux valeurs faibles du CAC (partie gauche du graphique), la corrélation devient beaucoup moins évidente :

Entrée [13]:

```
sns.scatterplot(data=df, x="cac", y="olg")
plt.xlim([4200, 4600])
plt.show()
```



Entrée []: